

PDF ou Markdown: qual formato serve melhor a base de conhecimento?

Estudo preparado para a Vibra | Assistente RAG sobre MongoDB Atlas Vector Search

1. Como o teste foi montado

A regra foi mudar uma coisa só. O formato do arquivo de origem é a única variável: o particionamento em trechos (RecursiveCharacterTextSplitter, 800 caracteres com 150 de sobreposição), o modelo de embeddings (voyage-3, 1024 dimensões), a busca híbrida (vetorial e léxica combinadas por fusão RRF, k=60), o reranking (rerank-2, oito melhores trechos) e o modelo que redige a resposta (claude-sonnet-4-6, temperatura zero) são exatamente os mesmos nos dois cenários.

Cada formato foi para um banco próprio no Atlas, com índices vetorial e léxico idênticos, de modo que uma busca nunca enxerga os trechos da outra base. Sem isso, os dois formatos competiriam entre si dentro da mesma consulta e o resultado não diria nada.

As perguntas e as respostas de referência foram extraídas do documento completo, fora de qualquer um dos dois índices. Isso é o que permite julgar os dois com a mesma régua. Cobrimos fatos pontuais, valores, datas, listas, estrutura de seções e, de propósito, conteúdo que só existe dentro de tabelas: era ali que esperávamos ver diferença.

Cada resposta recebeu três notas de 0 a 5. Acurácia mede se os fatos e números batem com o gabarito. Completude, se a resposta cobre tudo que deveria. Fidelidade, se o sistema afirmou algo que o documento não sustenta; nessa nota, admitir que não encontrou a informação vale nota máxima, ainda que zere a acurácia. Além dessas, medimos a cobertura de evidência, que não depende de julgamento nenhum: é a fração das palavras da citação-gabarito que aparecem no contexto recuperado. Ela separa o que é mérito da busca do que é mérito da redação.

2. As duas bases lado a lado

O documento usado no teste é o PDTIC 2025/2027 do Tribunal de Justiça de Goiás, um plano diretor de TIC público, com mais de cem páginas e forte presença de tabelas de ações, custos e indicadores. Serve bem como caso de teste porque reúne exatamente o tipo de conteúdo que costuma sofrer na extração: números que só fazem sentido junto do cabeçalho da coluna em que estão.

	PDF	Markdown
Arquivo	PDTIC_2025_2027.pdf	PDTIC_2025_2027.md
Loader	PyPDFLoader	TextLoader
Caracteres extraídos	122.166	131.859
Chunks indexados	210	303
Títulos (#) preservados	0	94
Linhas de tabela preservadas	0	163
Metadado de página por chunk	sim (nº real da página)	não (arquivo único, page=0)

A conversão para Markdown usou a biblioteca pymupdf4llm, que reconstrói a hierarquia de títulos e devolve as tabelas em sintaxe Markdown. A leitura do PDF usa o PyPDFLoader, que entrega texto corrido, uma página por vez. A linha de títulos e a de linhas de tabela da tabela acima resumem bem a diferença: o que no PDF vira texto solto, no Markdown continua sendo tabela.

3. O que os números dizem

Métrica	PDF	Markdown	Δ
Acurácia (0-5)	4.87	5.00	0.13
Completude (0-5)	5.00	5.00	0.00
Fidelidade (0-5)	4.67	4.67	0.00
Cobertura de evidência	99.3%	98.7%	-0.6%
Score de rerank (média)	0.750	0.941	0.191
Latência de recuperação (ms)	1320	894	-426

Em acurácia por pergunta: **1** vitórias do Markdown, **0** do PDF, **14** empates (de 15).

4. Acurácia por tipo de pergunta

Tipo	n	PDF	Markdown	Δ
data	1	5.00	5.00	+0.00
fato	2	5.00	5.00	+0.00
lista	3	4.33	5.00	+0.67
numero	4	5.00	5.00	+0.00
tabela	5	5.00	5.00	+0.00

5. Leitura dos resultados

A resposta à pergunta de origem é sim: a acurácia se mantém. O Markdown ficou em 5.00 de 5 e o PDF em 4.87, com 14 das 15 perguntas empatadas na nota máxima e nenhuma pergunta em que o PDF tenha ido melhor. A cobertura de evidência praticamente não se moveu (99.3% contra 98.7%), o que era esperado: a busca híbrida acha o trecho certo nos dois casos.

O ganho interessante não está na resposta final, e sim um passo antes dela. A nota média que o reranker atribui aos trechos recuperados subiu de 0.750 para 0.941, uma diferença de 25%. Esse número mede o quanto cada trecho, sozinho, responde à pergunta. E é aí que a estrutura preservada faz diferença: um trecho em Markdown costuma trazer o título da seção e a tabela inteira, cabeçalho incluído. No texto corrido extraído do PDF, a mesma tabela chega partida no meio, e o modelo recebe uma coluna de números sem o rótulo que diz o que eles são.

A recuperação também ficou mais rápida, 894 ms contra 1320 ms por consulta. Trechos mais coesos geram menos candidatos ambíguos para a fusão resolver.

Há uma contrapartida que precisa entrar na conta. O Markdown foi ingerido como um arquivo único, e arquivo único não tem paginação. Na prática, toda citação de origem passa a apontar para a página zero, enquanto a ingestão do PDF cita a página real. Num assistente cujo diferencial é mostrar de onde veio a resposta, isso é uma perda que o usuário enxerga. Dá para resolver convertendo página a página e guardando o número no metadado, mas é trabalho de ingestão, não um ganho que vem de graça com o formato.

Por fim, o custo de indexar. O Markdown produziu 303 trechos contra 210 do PDF, um aumento de 44%, porque a sintaxe de títulos e tabelas também ocupa caracteres. Mais trechos significam mais embeddings a gerar, mais espaço no índice vetorial e uma ingestão proporcionalmente mais demorada. Num documento desse tamanho é irrelevante; numa base com milhares de documentos, entra no orçamento.

6. Recomendação

Recomendamos adotar o Markdown como formato de ingestão. Do ponto de vista de acurácia a troca é segura, já que não houve piora em nenhuma das 15 perguntas, e a relevância dos trechos recuperados melhora de forma mensurável, principalmente em conteúdo tabular, que é justamente onde documentos de planejamento concentram os números que importam.

Duas condições acompanham a recomendação. A primeira é preservar o número da página durante a conversão, para não perder a citação de origem. A segunda é manter a conversão automatizada a partir do documento oficial: o PDF continua sendo a fonte da verdade e o Markdown passa a ser um artefato derivado, que qualquer pessoa consegue regerar quando o documento for revisado.

Sobre os limites do que foi medido: são 15 perguntas sobre um documento, com avaliação feita por um modelo. A diferença de acurácia entre os dois formatos é pequena demais para uma amostra desse tamanho sustentar, e por isso a conclusão honesta é de empate técnico, não de superioridade. Já a diferença nas notas de reranking vem direto do modelo de reranking e não depende de julgamento; é o achado mais sólido do estudo.

7. Pergunta a pergunta

#	Pergunta / tipo	PDF acc/comp/fid	MD acc/comp/fid	Cobertura PDF / MD
1	Qual é a resolução do CNJ que instituiu a Estratégia Nacional de Tecnologia da Informação e Comunicação do Poder Judiciário (ENTIC-JUD) para o sexênio 2021-2026? [tabela]	5 / 5 / 5	5 / 5 / 5	100% / 100%
2	Qual foi a pontuação do TJGO no índice iGovTIC-JUD nos anos de 2023 e 2024? [numero]	5 / 5 / 5	5 / 5 / 4	89% / 100%
3	Qual é o período de vigência do PDTIC 2025/2027 e quando está prevista a revisão anual obrigatória? [data]	5 / 5 / 5	5 / 5 / 4	100% / 100%
4	Das 124 ações planejadas no PDTIC 2023-2025, quantas foram concluídas, reagendadas, canceladas e não concluídas? [numero]	5 / 5 / 4	5 / 5 / 4	100% / 100%
5	Quais são as categorias estratégicas em que as ações do PDTIC foram organizadas? [lista]	3 / 5 / 2	5 / 5 / 4	100% / 100%
6	Qual é o custo estimado da ação AC 09, que trata do aprimoramento da infraestrutura de datacenter do TJGO? [numero]	5 / 5 / 5	5 / 5 / 5	100% / 100%
7	Qual unidade é responsável pela elaboração do PDTIC e qual instância é responsável por sua aprovação? [fato]	5 / 5 / 4	5 / 5 / 5	100% / 100%
8	O que significa a sigla COBIT conforme a tabela de abreviações e termos do documento? [tabela]	5 / 5 / 5	5 / 5 / 5	100% / 100%
9	Quais são os dois macrodesafios do Planejamento Estratégico 2021/2026 do TJGO aos quais as ações do PDTIC estão diretamente alinhadas? [lista]	5 / 5 / 5	5 / 5 / 5	100% / 100%
10	Qual é o custo estimado da ação AC 12, que trata da manutenção atualizada do parque computacional de TI do TJGO? [tabela]	5 / 5 / 5	5 / 5 / 5	100% / 100%
11	Qual é a composição do Comitê Gestor de Segurança da Informação (CGSI) conforme o Decreto nº 1.299/2025? [lista]	5 / 5 / 5	5 / 5 / 5	100% / 100%
12	Qual documento de referência trata da Política de Gestão de Pessoas de TIC no âmbito do Poder Judiciário do Estado de Goiás? [tabela]	5 / 5 / 5	5 / 5 / 5	100% / 100%
13	Qual é o objetivo principal (Objective) definido na metodologia OKR adotada para o monitoramento do PDTIC? [fato]	5 / 5 / 5	5 / 5 / 5	100% / 80%
14	Qual é o custo estimado da ação AC 05, que trata da contratação de solução tecnológica integrada para comunicação e trabalho colaborativo? [tabela]	5 / 5 / 5	5 / 5 / 4	100% / 100%
15	Em 2022, qual foi a posição do TJGO na classificação geral do ranking iGovTIC-JUD e qual nível de maturidade foi alcançado? [numero]	5 / 5 / 5	5 / 5 / 5	100% / 100%

8. A pergunta em que os dois formatos discordaram

Q5 [lista] — Quais são as categorias estratégicas em que as ações do PDTIC foram organizadas?

Gabarito: As ações foram organizadas nas seguintes categorias: Infraestrutura de TIC; Processo Judicial Digital (PROJUDI); Processo Administrativo Digital (PROAD); Processos Internos; e Sistemas e Suporte.

	Resposta	acc
PDF	Com base no contexto fornecido, as ações do PDTIC foram organizadas nas seguintes categorias estratégicas : 1. Infraestrutura de TIC (INFRA) — visam à manutenção e implantação da infraestrutura de TIC; 2. Processo Judicial Digital (PROJUDI) — visam à manutenção e evolução do sistema de processo judicial eletrônico; 3. Processo Administrativo Digital (PROAD) — visam à manutenção e evolução do sistema de processo administrativo eletrônico; 4. Processos Internos (PRIN) — visam à melhoria dos processos internos de TIC, buscando a otimização dos seus serviços e entregas; 5. Segurança (SEG) — visam à melhoria nos cuidados com a segurança da informação digital; 6. Sistemas	3
MD	Com base no contexto fornecido, as ações do PDTIC foram organizadas nas seguintes categorias estratégicas : 1. Infraestrutura de TIC 2. Processo Judicial Digital (PROJUDI) 3. Processo Administrativo Digital (PROAD) 4. Processos Internos 5. Sistemas e Suporte Essas categorias são detalhadas no Quadro de Ações Planejadas (Seção 9) do Plano Diretor.	5